

DataLake

Camada de Aquisição



Camada Bronze

- Recebe os dados brutos das origens
- Dados atualizados com frequência: diária
- Período de Armazenamento: 3 anos
- Dados armazenados em formato bruto
- Formato de Arquivo: parquet
- Estrutura de pastas: datalake/bronze/<origem_dados>/<ano>/<mes>/<dia>/<arquivo>.parquet
- Camada Responsável pela Linhagem/ histórico dos dados

Camada de Transformação



Camada Silver

- Recebe os dados mais atuais da Camada Bronze
- Dados atualizados com frequência: diária
- Armazena dados transformados
- Formato de Arquivo: parquet
- Estrutura de pastas: /datalake/silver/<origem_dados>/<arquivo>.parquet
- Realiza transformações como:
 - Padronização de nomenclatura e valores dos campos
 - junção de dados
 - Tratamento de valores nulos e/ou duplicados
 - Engenharia de atributos
 - Tratamento valores outliers
 - Conversão de tipos de dados
 - etc.
- Responsável pela qualidade dos dados

***OBS: os dados preferencialmente devem ser consumidos dessa camada ou da Camada Ouro**


Camada de Visualização



Camada Ouro

- Recebe os dados mais atuais da Camada Silver
- Dados atualizados com frequência de: Diário
- Armazena dados Agregados, conforme necessidade de cada área
- Formato de Arquivo: parquet
- Estrutura de pastas: refined-zone/<maquina>/<visao_ou_proposito>/<arquivo>.parquet
- Realiza transformações como:
 - Aplicação de regras de negócio
 - Agregações e métricas dos dados
 - Preparações processos de machine learning/IA
 - Remoção de stopwords
 - Codificação de variáveis categóricas
 - Normalização ou padronização de variáveis numéricas
 - Treinamento e teste dos modelos
 - etc.
- Responsável por armazenar dados após processos de machine learning ou Analytics
- Os dados dessa Camada também são replicados em um Banco de dados Relacional

***OBS: os dados preferencialmente devem ser consumidos dessa camada ou da Camada Silver**



*Orquestração da pipeline realizada pelo Apache Airflow